Transformer 架构阅读笔记

1 研究背景

主流的序列转换模型基于复杂的循环神经网络或卷积神经网络，包含编码器与解码器。

注意力机制已成为各类任务中的重要组件，但此前它通常与循环网络结合使用。

本文提出一种完全基于注意力机制的简单网络架构 Transformer，完全免除循环与卷积。

2 核心实验数据

The Transformer uses scaled dot-product attention with 8 attention heads and 6 encoder layers.

It reaches 28.4 BLEU on WMT 2014 English-to-German translation, outperforming ensemble models.

On English-to-French, the big Transformer model achieves 41.8 BLEU with a single model.

该架构并行化程度更高，在 8 块 P100 GPU 上训练 3.5 天即可达到当时最优效果。

3 主要结论

多头注意力允许模型在不同位置共同关注来自不同表示子空间的信息。

实验表明，自注意力可以显著提升翻译质量，且训练成本远低于循环模型。

4 参考文献

[1] Vaswani et al. Attention Is All You Need. NeurIPS 2017.

[2] Bahdanau et al. Neural Machine Translation by Jointly Learning to Align and Translate. ICLR 2015.